PLAN OPERATIVO HACKATHON AMD ACTO 3

Ventana de Ejecución: 12 al 18 de Octubre • Arquitectura de Borde & Aceleración Silicio AMD

BIO-EDGE AMD

1. DEFINICIÓN DEL PROYECTO: SISTEMA AUTÓNOMO BIO-EDGE AMD

Bio-Edge AMD • Monitoreo Ecológico & Conteo Inteligente en el Borde

Visión por Computadora & Inferencia de Bajo Consumo

Problema & Propuesta de Valor: Los sistemas tradicionales de foto-trampeo en reservas ecológicas acumulan gigabytes de video que deben extraerse físicamente y procesarse semanas después en la nube, perdiendo la capacidad de alertar incursiones furtivas o censar dinámicamente especies en peligro. **Bio-Edge AMD** es una solución embebida de borde que realiza inferencia y telemetría in-situ, procesando flujos de video localmente con ultra-baja latencia y eficiencia energética, sin requerir conexión a internet.

1. INGESTA DE VIDEO

Captura RTSP/Webcam multihilo con decodificación eficiente y normalización de resolución sin saturar CPU.

2. ACELERACIÓN AMD

Inferencia en ONNX Runtime con Vitis AI EP / DirectML / ROCm sobre modelo YOLO cuantizado a INT8/FP16.

3. TRACKING & ROI

Seguimiento por centroides (ByteTrack liviano), conteo direccional por cruce y persistencia en SQLite.

4. TELEMETRÍA & UI

Servidor FastAPI emitiendo streaming procesado y métricas de aceleración vía WebSockets a un dashboard.

2. DIFERENCIAL TÉCNICO Y MÉTRICAS PARA EL JURADO DE AMD

Alineación con la Pila Tecnológica de AMD

No se ejecuta inferencia genérica en Python. Se evalúa de forma explícita el motor de cómputo del silicio AMD (GPU Radeon vía ROCm / DirectML o NPU Ryzen AI con Vitis AI EP), cuantizando grafos a precisión reducida (INT8) para maximizar FPS por Vatio.

Métricas Cuantitativas de Éxito (KPIs del MVP)

Latencia: Reducción de >110 ms (CPU estándar) a <25 ms con acelerador AMD.
Cadencia: >45 FPS sostenidos en video 1080p.
Precisión: Retención de mAP@50 >94% tras cuantización INT8.

3. ESTRATEGIA DE RESILIENCIA OPERATIVA (PAIRING ASÍNCRONO)

FRENTE A • CORE IA & SILICIO

Titular: Emilio • Co-Lead: Angela

Optimización y cuantización del modelo de visión, benchmarking riguroso e integración con el runtime AMD.

FRENTE B • PIPELINE & SOFTWARE

Titular: Cisneros • Backup: Angel

Arquitectura modular del motor desacoplado, tracking en tiempo real, persistencia local y backend FastAPI.

FRENTE C • FRONTEND & DESPLIEGUE

Titular: Elida • Backup: Mario

Dashboard reactivo para telemetría, visualizador de comparativas CPU vs. AMD, Docker reproducible y video demo.

4. ASIGNACIÓN EXHAUSTIVA DE RESPONSABILIDADES Y TAREAS (PARTE 1)

Emilio — Líder Técnico & Hardware Acceleration Lead

Frente A (Titular)

TAREAS TÉCNICAS DIRECTAS

- Configurar drivers de hardware AMD (ROCm en Linux o NPU Ryzen AI con Vitis AI EP / DirectML en Windows).
- Adaptar el wrapper de inferencia en ONNX Runtime para inicializar proveedores de aceleración de AMD.
- Realizar profiling de hardware: medir porcentaje de uso de NPU/GPU, consumo de VRAM y temperatura.
- Construir el script de ejecución maestro `run_edge.py` con banderas de configuración dinámica.

ENTREGABLES & CONTINGENCIA

- **Entregable:** Script `inference_amd.py` funcional y reproducible con fallback automático.
- **Entregable:** Matriz de compatibilidad documentada en `SETUP_AMD.md`.
- **Protocolo de Cobertura:** Si Emilio no está disponible, Angela asume la ejecución de inferencia y profiling en la máquina con hardware AMD.

Angela — Ingeniera en TI & Especialista en IA (Co-Lead Modelos & Benchmarks)

Frente A (Co-Lead)

TAREAS TÉCNICAS DIRECTAS

- Seleccionar y preparar el modelo base de visión (YOLOv8-nano / FastViT preentrenado para fauna y detección de intrusos).
- Ejecutar el pipeline de cuantización de precisión (FP32 a INT8 y FP16) mediante Vitis AI Quantizer o ONNX Runtime.
- Evaluar la degradación de precisión (validación de mAP@50 en dataset de prueba post-cuantización).
- Diseñar y programar la suite de benchmarking automatizado (`benchmark.py`) para calcular latencia P50/P95/P99.

ENTREGABLES & CONTINGENCIA

- **Entregable:** Modelos optimizados en formato `.onnx` (FP16 e INT8 listos para ejecución).
- **Entregable:** Reporte cuantitativo con tablas comparativas de throughput (FPS) y latencia (ms).
- **Protocolo de Cobertura:** Respalda a Emilio en la ejecución sobre silicio AMD; Cisneros puede consumir sus modelos exportados sin fricción.

Cisneros — Ingeniero en TI Senior (Arquitectura de Software & Backend)

Frente B (Titular)

TAREAS TÉCNICAS DIRECTAS

- Diseñar la arquitectura de software modular en Python: clase abstracta `BaseInferenceEngine` desacoplada del proveedor de hardware.
- Implementar el bucle de captura y preprocesamiento de video con OpenCV multihilo para eliminar cuellos de botella en lectura.
- Desarrollar la API en FastAPI exponiendo endpoints de telemetría y WebSocket para streaming de frames a 30+ FPS.
- Gestionar el ciclo de vida de la aplicación y manejo robusto de excepciones ante cortes del flujo de video.

ENTREGABLES & CONTINGENCIA

- **Entregable:** Módulo central `pipeline.py` y servidor de servicios `main_server.py`.
- **Entregable:** Documentación de endpoints en OpenAPI/Swagger.
- **Protocolo de Cobertura:** Si Cisneros se ausenta, Angel asume el mantenimiento de las rutas de la API y la conexión con el bucle de captura.

4. ASIGNACIÓN EXHAUSTIVA DE RESPONSABILIDADES Y TAREAS (PARTE 2)

Angel — Estudiante de Ing. de Software (Lógica de Visión & Tracking)

Frente B (Backup Cisneros)

TAREAS TÉCNICAS DIRECTAS

- Implementar tracking de objetos mediante seguimiento por centroides o ByteTrack liviano para asignar IDs únicos.
- Programar conteo direccional por cruce de líneas virtuales o zonas de interés poligonal (ROI).
- Configurar almacenamiento persistente en SQLite local para registrar marcas de tiempo, clase y confianza.

ENTREGABLES & CONTINGENCIA

- **Entregable:** Módulos `tracker.py` y `storage.py` probados con datos de video simulados.
- **Protocolo de Cobertura:** Cisneros valida la integración; Angel puede sustituir a Cisneros en ajustes del backend.

Elida — Estudiante de Ing. en TI (Frontend & Dashboard Reactivo)

Frente C (Titular)

TAREAS TÉCNICAS DIRECTAS

- Diseñar dashboard web interactivo con visualización en tiempo real del stream con bounding boxes superpuestos.
- Construir módulo de telemetría: contadores dinámicos de especies detectadas y gráfico de distribución temporal.
- Crear panel visual de benchmarks para la demo del jurado (comparativa gráfica en vivo: latencia CPU vs. AMD).

ENTREGABLES & CONTINGENCIA

- **Entregable:** Directorio `frontend/` funcional, consumiendo WebSocket o mock stream.
- **Protocolo de Cobertura:** Mario asiste con estilos y armado de componentes si Elida requiere apoyo.

Mario — Estudiante de Ing. en TI (DevOps, Documentación & Video Demo)

Frente C (Backup Elida)

TAREAS TÉCNICAS DIRECTAS

- Construir el `Dockerfile` y entorno de ejecución garantizando reproducibilidad en máquinas de evaluadores.
- Redactar el `README.md` estructurado con guías de instalación en 3 pasos, arquitectura y badges de AMD.
- Grabar, editar y producir el video demo de 3 minutos destacando el silicio AMD en ejecución y el dashboard final.

ENTREGABLES & CONTINGENCIA

- **Entregable:** Contenedor reproducible probado en máquina limpia y video demo en alta resolución.
- **Protocolo de Cobertura:** Respalda a Elida en frontend; Angela audita la documentación técnica generada.

5. CRONOGRAMA DIARIO DE EJECUCIÓN (12 AL 18 DE OCTUBRE)

FECHA	HITO PRINCIPAL	TAREAS OPERATIVAS POR FRENTE
Lun 12	Setup & Baseline	Repo configurado. Angela y Emilio exportan modelo base a ONNX y miden CPU baseline. Cisneros inicia estructura de clases.
Mar 13	Aceleración AMD	Emilio activa execution provider AMD; Angela cuantiza a INT8. Cisneros y Angel arman captura. Elida inicia UI con mock data.
Mié 14	Tracking & API	Angel conecta tracking y persistencia SQLite. Cisneros expone streaming por WebSockets. Mario prepara Dockerfile preliminar.
Jue 15	Integración Total	Pipeline completo en vivo: Video ➔ Inferencia AMD INT8 ➔ Tracking ➔ FastAPI ➔ Dashboard de Elida. Depuración de I/O.
Vie 16	Benchmarks & Freeze	Angela y Emilio corren matriz cuantitativa final (latencias ms, FPS, memoria). *Code Freeze* a las 18:00 hrs.
Sáb 17	Video Demo & Docs	Mario y Elida graban y editan el video de pitch (máx 3 min). Redacción del README con tablas y diagramas técnicos.
Dom 18	Release & Entrega	Prueba de clonación en limpio en equipo ajeno. Verificación de permisos y envío formal de entrega antes de la hora límite.

6. POLÍTICAS DE AUTONOMÍA Y CERO BLOQUEOS

Fallback Mandatorio a CPU

Todo comando acepta `--device cpu` por defecto, permitiendo que cualquier integrante desarrolle sin requerir silicio AMD específico.

Desacoplamiento con Mocks

El frontend consume un simulador local (`mock_stream.py`), avanzando en diseño y componentes sin depender del backend.

Standup Asíncrono Diario

Reporte breve al final del día: 1) Completado hoy (con commit), 2) Tarea de mañana, 3) Bloqueos identificados.

Matriz de Cobertura Inmediata

Si falta Emilio → cubre Angela. Si falta Cisneros → cubre Angel. Si falta Elida → cubre Mario (y viceversa en cada par).